Arvio

Variantti `baseline` · malli `night-runner:latest` · 2026-10-03T18:25:46+00:00

Katselmoijalle

Mihin tehtäviin tämän voi ohjata. Ei yhtään arvioitua tehtävää.

Mitä yksi onnistuminen maksoi. Ei yhtään tehtävää, joka onnistui joka kerta, joten minuuttia per onnistuminen ei jaeta. Yhteensä 0 minuuttia.

Muuttuiko tulos. Ero edelliseen mahtuu satunnaiseen heittoon, älä tulkitse sitä muutokseksi.

Tehtävät ryhmittäin

Ryhmä	Tehtäviä	Merkitys
Luotettava	0	Onnistui joka kokeilukerta.
Hauras	0	Onnistuu vain joskus.
Ei osaa	0	Testit eivät menneet kertaakaan.

Tekijälle

Voiko valmis-merkintää uskoa. Yksikään ajo ei merkinnyt tehtävää valmiiksi.

Onko odotusaika käyttökelpoinen. Aikaa ei ole kirjattu. Askelmäärää ei ole tässä lokissa.

Mihin korjaus kohdistuu. Yksikään ajo ei epäonnistunut.

Aika ja askeleet

	Tyypillinen	Hitain	Kertoja
Minuutteja	—	—	0
Askeleet	ei kirjattu	—	0

Mihin ajot kaatuivat

Syy	Ajot
aikakatkaisu	0
silmukka	0
työkaluvirheet	0
askelbudjetti	0
testit	0
muu	0

Epäonnistuneita ajoja 0.

Läpäisy kriteereittäin

Kriteeri	Osuus	Heitto	Kertoja	Ero edelliseen

Mitä arvioidaan

Valmis-merkintä

Agentti merkitsi tehtävän valmiiksi ja tarkistus hyväksyi sen.

Miksi: Sujuvakaan keskustelu ei riitä, jos tehtävää ei merkitä valmiiksi.

Miten: Luetaan tehtävän tila ajon jälkeen. Läpi vain, jos tila on valmis.

Testit

Aiemmin hyväksytyn version testit menevät läpi agentin kirjoittamalla koodilla.

Miksi: Agentin omat testit voivat olla liian heikot. Nämä ovat regressiotestejä, eivät erillisiä piilotestejä.

Miten: Ajon jälkeen ajetaan hyväksytyn version testitiedostot.

Prosessiraja

Agentti valmistui ilman silmukkaa, askelbudjetin loppumista tai työkaluvirheiden tulvaa.

Miksi: Paikallinen malli epäonnistuu usein tapaan tehdä työtä, ei vain vastauksen oikeellisuuteen.

Miten: Luetaan ajon yhteenveto. Hylätään, jos yrityksiä on yli 10, askeleita yli 160, sama työkalukutsu toistuu yli 5 kertaa, tai työkaluvirheiden osuus on yli 40%.

Epäonnistumiset ensin

Ei epäonnistuneita ajoja.

Haurat tehtävät

Sama tehtävä, eri kerrat. Nämä kannattaa lukea ensin.

Ei sekoittuneita tuloksia (tarvitaan vähintään 2 kertaa).